Techniques Algorithmiques et Programmation

# Paire de points les plus proches

On va étudier un algorithme qui prend en entrée un ensemble de points $P$ du plan et retourne la paire de points les plus proches, et qui répond rapidement en moyenne.

Étant donné un réel $\delta > 0$, la *cellule* d'indice $(i, j)$, où $i, j$ sont entiers, est la région carrée du plan de coté $\delta$ correspondant à $[i\delta, (i+1)\delta[\times[j\delta, (j+1)\delta[$. Notez que les cellules partitionnent le plan.

Dans l'algorithme qui suit, on visite chaque point de $P$ dans l'ordre $p_0, p_1, \ldots, p_t, \ldots$. À l'étape $t$, on aura besoin de déterminer rapidement si une cellule $(i, j)$ contient un des points déjà visités. On va le faire grâce à une *table de hachage* $T_\delta$ indexée par les indices $(i, j)$ des cellules et contenant une liste de points. Donc $T_\delta[(i, j)] = \{p_{t_1}, p_{t_2}, \ldots\}$ représente l'ensemble courant (éventuellement vide) des points déjà recontrés et appartenant à la cellule $(i, j)$.

Algorithme pppp_random($P$)

**Entrée :** Une suite $P = (p_0, p_1, \ldots, p_{n-1})$ de $n \geqslant 2$ points du plan.
**Sortie :** La paire de points les plus proches.

1. Poser $d_{\min} := d(p_0, p_1)$ et $R := \{p_0, p_1\}$.
2. Créer une table de hachage $T_\delta$ de cellules de paramètre $\delta := d_{\min}/\sqrt{2}$.
3. Pour chaque point $p_t \in P$ dans l'ordre $t := 0, 1, \ldots, n-1$ :
   (a) Soit $(i, j) := (\lfloor x(p_t)/\delta \rfloor, \lfloor y(p_t)/\delta \rfloor)$ la cellule du point $p_t$.
   (b) Chercher dans la table $T_\delta$ le point $q$ qui, parmi les cellules "voisines" de $(i, j)$, soit le plus proche de $p_t$.
   (c) Si $q$ existe[1] et si $d(p_t, q) < d_{\min}$, poser $d_{\min} := d(p_t, q)$, $R := \{p_t, q\}$ et aller en (2).
   (d) Ajouter $p_t$ à $T_\delta[(i, j)]$.
4. Renvoyer $R$.

**Question 1.** *Montrez qu'à chaque instant de l'algorithme, $T_\delta[(i, j)]$ contient au plus un seul élément.*

**Question 2.** *L'algorithme ne précise pas en (3b) ce qu'est une cellule "voisine" de $(i, j)$. Pouvez-vous préciser ? Combien de cellules faut-il considérer au maximum ? au minimum ?*

**Question 3.** *Montrez que si la boucle en (3) termine, c'est-à-dire que le test en (3c) n'est jamais vrai, alors les deux points de $P$ les plus proches sont à distance $\geqslant d_{\min}$. En déduire que l'algorithme pppp_random($P$) calcule dans $R$ la paire de points la plus proche.*

On supposera qu'on dispose d'une implémentation de table de hachage permettant la création, la lecture et l'insertion en temps constant (en moyenne).

**Question 4.** *Pourquoi n'est-il pas judicieux d'utiliser, à la place d'une table de hachage $T_\delta[(i, j)]$, un simple tableau à deux dimensions $T_\delta[i][j]$ ?*

1. Toutes les cellules "voisines" de $(i, j)$ pourraient être vides.

On dira qu'il y a *échec à l'indice* $t$ si le test en (3c) devient vrai pour $p_t$. Le coût total de l'algorithme, c'est-à-dire sa complexité en temps, peut donc se décomposer en une suite d'échecs jusqu'au moment où la boucle en (3) se termine sans échec.

**Question 5.** *Quel est le coût de la boucle en (3) lorsqu'il y a échec à l'indice $t$ ?*

**Question 6.** *Montrez que s'il y a un échec à l'indice $t$ puis un échec à l'indice $t'$, alors $t' > t$. En déduire la complexité de* pppp_random$(P)$ *dans le pire des cas. Décrire une suite de points qui atteint ce pire cas.*

**Question 7.** *Montrez que si les points sont permutés aléatoirement uniformément dans $P$, alors la probabilité d'avoir un échec à l'indice $t$ est au plus la probabilité que $p_t$ réalise la plus petite distance entre deux points d'indice $\leqslant t$. En déduire que la probabilité d'avoir un échec à l'indice $t$ est $\leqslant t/\binom{t+1}{2}$.*

**Question 8.** *En déduire que la complexité moyenne de l'algorithme qui commencerait par permuter aléatoirement les points et qui appliquerait* pppp_random$(P)$ *est en $O(n)$.*

Pour implémenter $T_\delta$ on aura besoin de coder chaque couple d'entiers $(i, j) \in \mathbb{N}^2$ vers un entier unique noté $\mathsf{map}(i, j)$. En représentant chaque couple $(i, j)$ par un point d'une grille, on définit alors $\mathsf{map}(i, j)$ comme le nombre de points rencontrés en partant de $(0, 0)$ et jusqu'à atteindre $(i, j)$ (sans le compter) en empruntant les diagonales du type $(t, 0) \to (0, t)$ (voir la figure). On aurait pu prendre $2^i \cdot 3^j$, mais c'est plus couteux à calculer.

Dans l'exemple ci-dessous, $\mathsf{map}(3, 1) = 11$ car il y a exactement 11 points sur les diagonales situées avant $(3, 1)$. Notez que la dernière diagonale qui contient $(i, j)$ démarre à l'abscisse $i + j = 4$.

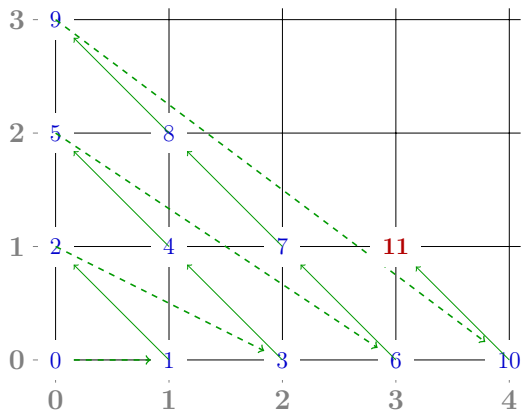


**Question 9.** *Montrez que* $\mathsf{map}(i, j) = \left(\sum_{t=0}^{i+j-1}(t + 1)\right) + j$, *et en déduire une formule close.*

# En TP

Télécharger les fichiers correspondant au TP à partir de la page de l'UE disponible ci-après :

http://dept-info.labri.fr/~gavoille/UE-TAP/

Complétez le fichier `pppp.c` afin d'implémenter les trois algorithmes (fonctions) `pppp_naive()`, `pppp_random()` et `pppp_divide()` décrites dans `pppp.h`.

Pour ce TP, on va réutiliser `tsp_main.c` qui va permettre de visualiser la paire de points la plus proche, de tester les fonctions sur des exemples particuliers, etc. Dans `tsp_main.c`, il faudra :

- décommenter `#include "tsp_brute_force.h"` pour la fonction de distance `dist()`
- décommenter `#include "tsp_mst.h"` (pour `createGraph`) et bien sûr `#include "pppp.h"`
- désactiver les parties liées au TSP, notamment `#ifdef TSP_BRUTE_FORCE_H` et `#ifdef TSP_MST_H`
- commenter `#include "tsp_prog_dyn.h"` et `#include "tsp_heuristic.h"`